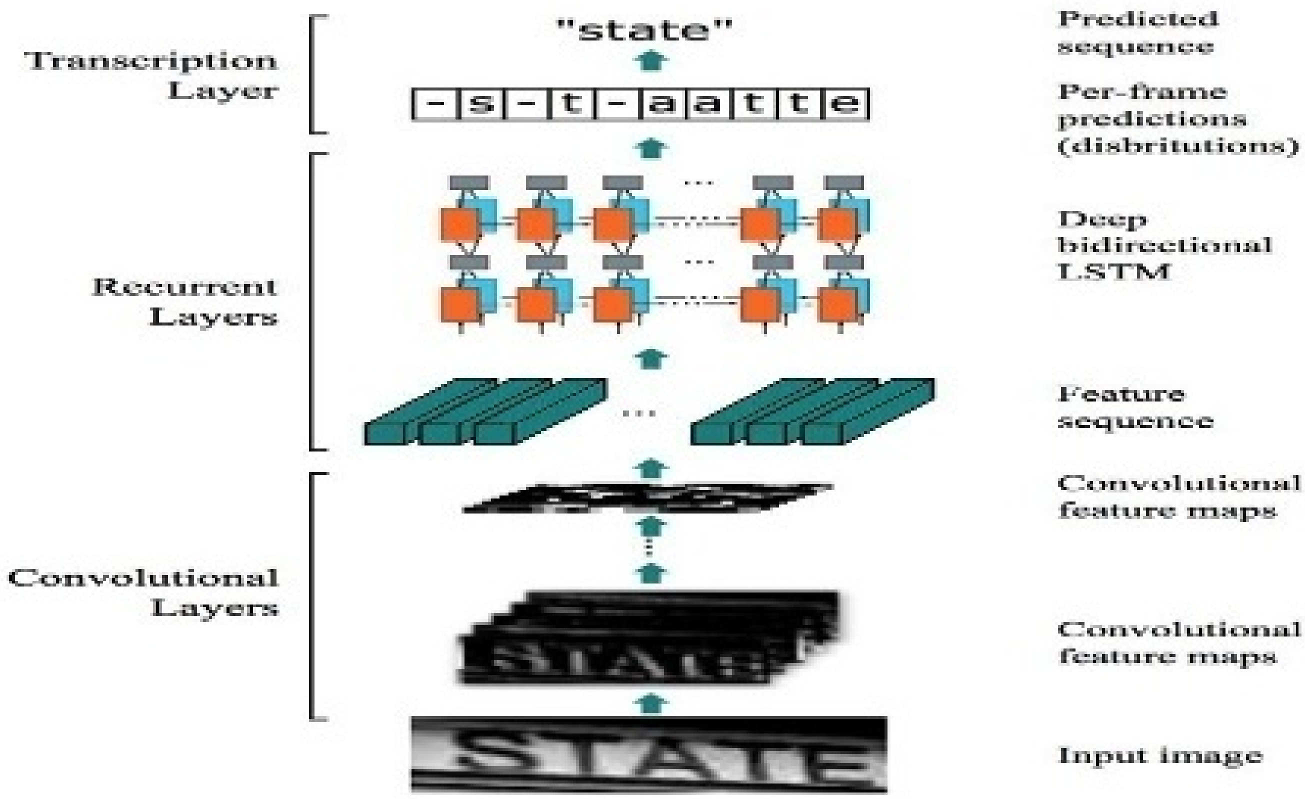

一文读懂CRNN+CTC文字识别

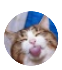

白裳
觉得不错就关注一下呗。

文字识别也是图像领域一个常见问题。然而，对于自然场景图像，首先要定位图像中的文字位置，然后才能进行识别。

所以一般来说，从自然场景图片中进行文字识别，需要包括2个步骤：

- 文字检测：解决的问题是哪里有文字，文字的范围有多
- 文字识别：对定位好的文字区域进行识别，主要解决的问题是每个文字是什么，将图像中的文字区域进转化为字符信息。

图1 文字识别的步骤

对于文字检测不了解的读者，请参考本专栏文章：

场景文字检测—CTPN原理与实现
zhuanlan.zhihu.com

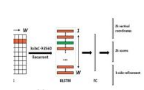

图2 文字检测定位文字图像区域

常用文字识别算法主要有两个框架：

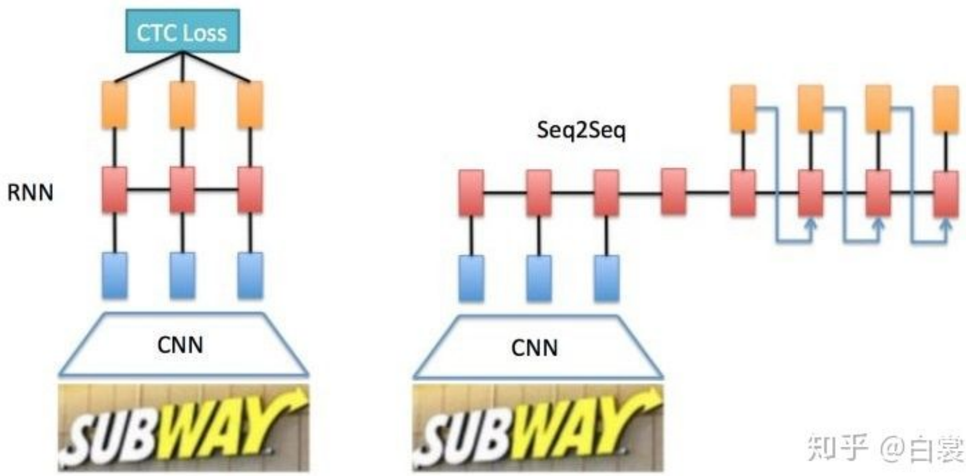

图3 文本行识别2种基本算法框架

1. CNN+RNN+CTC(CRNN+CTC)
2. CNN+Seq2Seq+Attention

本文主要介绍第一种框架CRNN+CTC，对应paper：

An End-to-End Trainable Neural Network for Image-based Sequence...
arxiv.org

对应代码（Tensorflow实现）：

bai-shang/OCR_TF_CRNN_CTC
github.com

CRNN基本网络结构

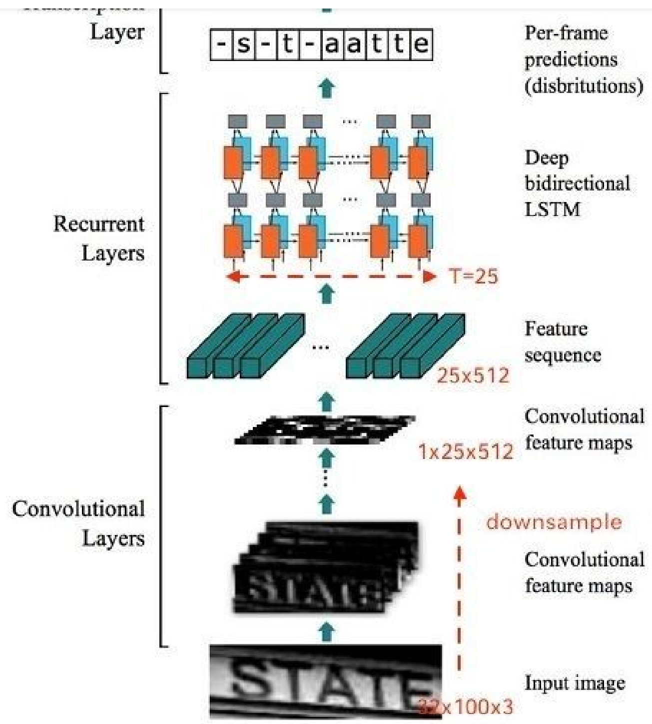

图4 CRNN网络结构（此图按照本文github实现画的）

整个CRNN网络可以分为三个部分，如图4。

假设输入图像大小为 $(32, 100, 3)$，注意提及图像都是 $(\mathrm{Height}, \mathrm{Width}, \mathrm{Channel})$ 形式。

- Convlutional Layers

这里的卷积层就是一个普通的CNN网络，用于提取输入图像的Convolutional feature maps，即将大小为 $(32, 100, 3)$ 的图像转换为 $(1, 25, 512)$ 大小的卷积特征矩阵。

- Recurrent Layers

这里的循环网络层是一个深层双向LSTM网络，在卷积特征的基础上继续提取文字序列特征。对RNN不了解的读者，建议参考：

完全解析RNN, Seq2Seq, Attention注意力机制
zhuanlan.zhihu.com

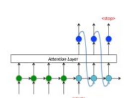

所谓深层RNN网络，是指超过两层的RNN网络。对于单层双向RNN网络，结构如下：

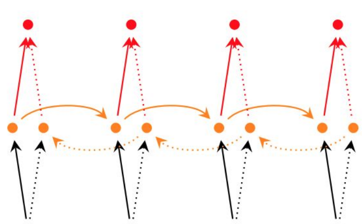

图5 单层双向RNN网络

而对于深层双向RNN网络，主要有2种不同的实现：

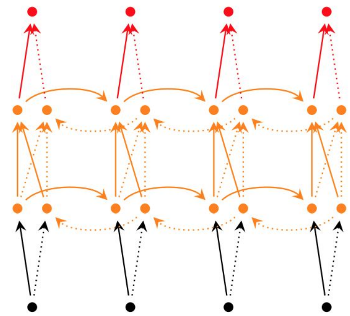

图6 深层双向RNN网络

```
tf.contrib.rnn.stack_bidirectional_dynamic_rnn
```

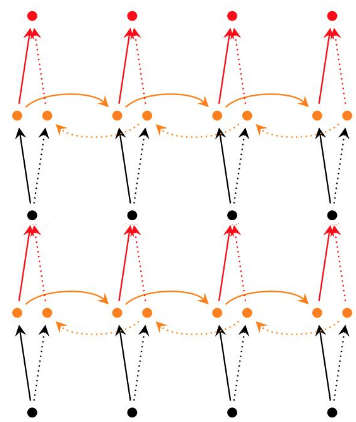

图7 stack形深层双向RNN网络

在CRNN中显然使用了第二种stack形深层双向结构。

由于CNN输出的Feature map是$(1,25,512)$大小，所以对于RNN最大时间长度 $T=25$ （即有25个时间输入，每个输入 x_t 列向量有 $D=512$ ）。

- Transcription Layers

将RNN输出做softmax后，为字符输出。

关于输入图片大小的解释：

在上文给出的实现中，为了将特征输入到Recurrent Layers，做如下处理：

- 首先会将图像缩放到 $32\times W\times 3$ 大小
- 然后经过CNN后变为 $1\times(W/4)\times 512$
- 接着针对LSTM，设置 $T=(W/4)$ ， $D=512$ ，即可将特征输入LSTM。

所以在处理输入图像的时候，建议在保持长宽比的情况下将高缩放到 32，这样能够尽量不破坏图像中的文本细节（当然也可以将输入图像缩放到固定宽度，但是这样由于破坏文本的形状，肯定会造成性能下降）。接下来是原理相关讲解。

考虑训练Recurrent Layers时的一个问题：

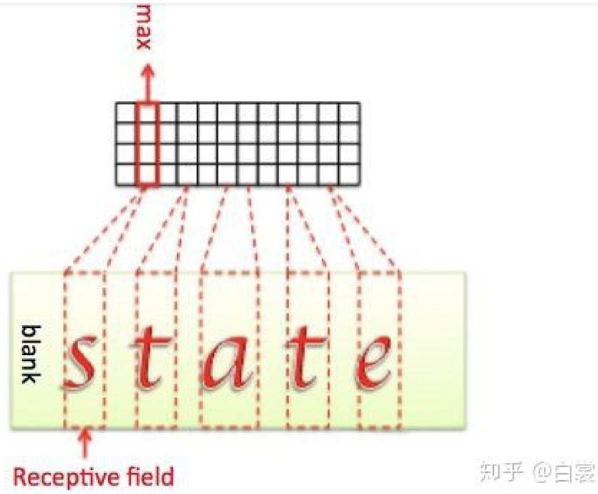

图8 感受野与RNN标签的关系

对于Recurrent Layers，如果使用常见的Softmax Loss，则每一列输出都需要对应一个字符元素。那么训练时候每张样本图片都需要标记出每个字符在图片中的位置，再通过CNN感受野对齐到Feature map的每一列获取该列输出对应的Label才能进行训练，如图8。

在实际情况中，标记这种对齐样本非常困难（除了标记字符，还要标记每个字符的位置），工作量非常大。另外，由于每张样本的字符数量不同，字体样式不同，字体大小不同，导致每列输出并不一定能与每个字符一一对应。

当然这种问题同样存在于语音识别领域。例如有人说话快，有人说话慢，那么如何进行语音帧对齐，是一直以来困扰语音识别的巨大难题。

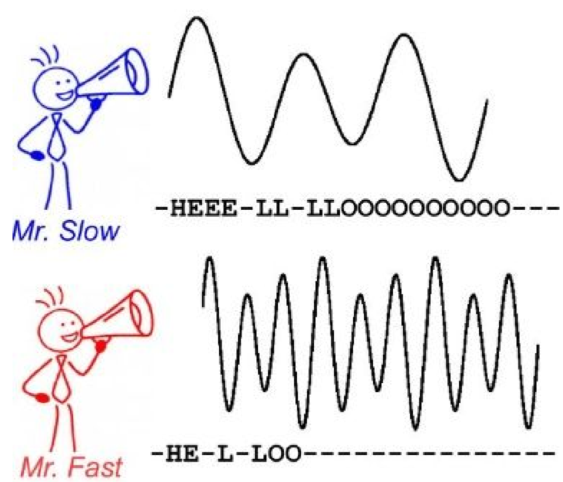

图9

所以CTC提出一种对不需要对齐的Loss计算方法，用于训练网络，被广泛应用于文本行识别和语音识别中。

Connectionist Temporal Classification(CTC)详解

在分析过程中尽量保持和原文符号一致。

Connectionist Temporal Classification:
Labelling Unsegmented Sequence...

整个CRNN的流程如图10。先通过CNN提取文本图片的Feature map，然后将每一个channel作为 $D=512$ 的时间序列输入到LSTM中。

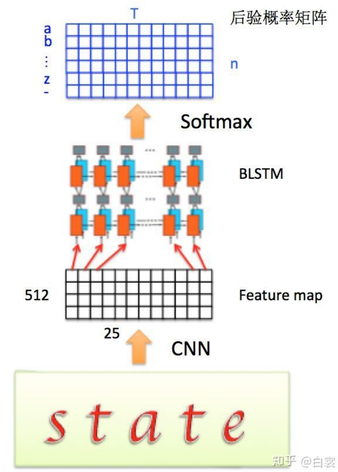

图10 CRNN+CTC框架

为了说明问题，我们定义：

- CNN Feature map

Feature map的每一列作为一个时间片输入到LSTM中。设Feature map大小为 $m \cdot T$ （图10中 $m=512$ ， $T=25$ ）。下文中的时间序列 t 都从 $t=1$ 开始，即 $1 \leq t \leq T$ 。

定义为：

$$x=(x^1, x^2, \ldots, x^T)$$

其中每一列为：

$$x^t=(x_1^t, x_2^t, \ldots, x_m^t)$$

- LSTM

LSTM的每一个时间片后接softmax，输出 y 是一个后验概率矩阵，定义为：

$$y=(y^1, y^2, \ldots, y^T)$$

其中每一列为：

$$y^t=(y_1^t, y_2^t, \ldots, y_n^t)$$

其中 n 代表需要识别的字符集合长度。由于是概率所以： $\sum_k y_k^t=1$

对 y 每一列进行 $\mathbf{argmax}()$ 操作，即可获得每一列输出字符的类别。

那么LSTM可以表示为：

其中 w 代表LSTM的参数。LSTM在输入和输出间做了如下变换：

$$N_w : (R^m)^T \rightarrow (R^n)^T$$

- 空白blank符号

如果要进行 $L = \{a, b, c, \ldots, x, y, z\}$ 的26个英文字符识别，考虑到有的位置没有字符，定义插入blank的字符集合：

$$L' = L \cup \{\text{blank}\}$$

其中blank表示当前列对应的图像位置没有字符（下文以 $-$ 符号表示blank）。

- 关于 B 变换

定义变换 B 如下（原文是大写的 β ，知乎没这个符号）：

$$B : L'^T \rightarrow L^{\leq T}$$

其中 L' 是上述加入blank的长度为 T 的字符集合，经过 B 变换后得到原始 L ，显然对于 L 的最大长度有 $|L| \leq T$ 。

举例说明，当 $T = 12$ 时：

$$B(\pi_1) = B(- - s\ t\ t\ a - t - - - e) = state$$
$$B(\pi_2) = B(s\ s\ t - a\ a\ a - t\ e\ e -) = state$$
$$B(\pi_3) = B(- - s\ t\ t\ a\ a - t\ e\ e -) = state$$
$$B(\pi_4) = B(s\ s\ t - a\ a - t - - - e) = state$$

对于字符间有blank符号的则不合并：

$$B(\pi_5) = B(-\ s\ t\ a - a\ t\ t\ e -\ e -) = staatee$$

当获得LSTM输出 y 后进行 B 变换，即可获得输出结果。显然 B 变换不是一一映射，例如对于不同的 $\pi_1 \sim \pi_4$ 都可获得英文单词state。同时 $|L| = |state| = 5 \leq 12$ 成立。

那么CTC怎么做？

对于LSTM给定输入 x 的情况下，输出为 l 的概率为：

$$p(l|x) = \sum_{\pi \in B^{-1}(l)} p(\pi|x)$$

其中 $\pi \in B^{-1}(l)$ 代表所有经过 B 变换后是 l 的路径 π 。

其中，对于任意一条路径 π 有：

注意这里的 $y^t_{\pi_t}$ 中的 π_t ，下标 t 表示 π 路径的每一个时刻；而上面 $\pi_1 \sim \pi_4$ 的下标表示不同的路径。两个下标含义不同注意区分。

顺带一提，注意上式 $p(\pi|x)$ 成立有条件：

- 输出 $y = (y^1, y^2, ..., y^T)$ 之间没有连接，也没有除了LSTM其他从 y 到 x 的反馈连接。

只有这样才 y_i 之间才能在条件 x 下独立。如加入图11中的反馈连接后，上述条件独立则不成立了。

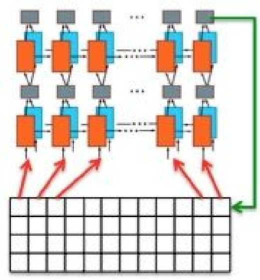

图11

此项不做进一步讨论，有兴趣的读者请自行研究。

如对于 $T = 12$ 的路径 π 来说：

$$\pi = (- - s\ t\ t\ a - t - - - e)$$

$$p(\pi|x) = y^1_- \cdot y^2_- \cdot y^3_s \cdot y^4_t \cdot y^5_t \cdot y^6_a \cdot y^7_- \cdot y^8_t \cdot y^9_- \cdot y^{10}_- \cdot y^{11}_- \cdot y^{12}_e$$

实际情况中一般设置 $T \geq 20$ ，所以有非常多条 $\pi \in B^{-1}(l)$ 路径，即 $|B^{-1}(l)|$ 非常大，无法逐条求和直接计算 $p(l|x)$ 。需要一种有效快速计算方法。

CTC的训练目标

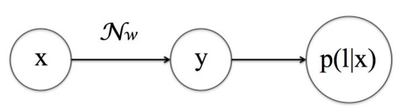

图12

CTC的训练过程，本质上是通过梯度 $\frac{\partial p(l|x)}{\partial w}$ 调整LSTM的参数 w ，使得对于输入样本为 $\pi \in B^{-1}(l)$ 时有 $p(l|x)$ 取得最大。

例如下面图13的训练样本，目标都是使得 $l = state$ 时的输出 $p(l|x)$ 变大。

图13

CTC借用了HMM的“向前—向后”(forward-backward)算法来计算 $p(l|x)$

要计算 $p(l|x)$ ，由于有blank的存在，定义路径 l' 为在路径 l 每两个元素以及头尾插入blank。那么 $\forall l'_i \in L'$ ，其中 $L' = L \cup \{blank\}$ 。如：

$$l = state$$

$$l' = -s-t-a-t-e-$$

显然 $|l'| = 2|l|+1$ ，其中 $|l|$ 是路径的最大长度，如上述例子中 $|l| = |state| = 5$ 。

定义所有经 B 变换后结果是 l 且在 t 时刻结果为 l_k （记为 $\pi_t = l_k$ ）的路径集合为 $\{\pi|\pi \in B^{-1}(l), \pi_t = l_k\}$ 。

求导：

$$\begin{aligned}\frac{\partial p(l|x)}{\partial y_k^t} &= \frac{\partial \sum_{\pi \in B^{-1}(l)} p(\pi|x)}{\partial y_k^t} \\ &= \frac{\partial \sum_{\pi \in B^{-1}(l), \pi_t = l_k} p(\pi|x)}{\partial y_k^t} + \frac{\partial \sum_{\pi \in B^{-1}(l), \pi_t \neq l_k} p(\pi|x)}{\partial y_k^t}\end{aligned}$$

注意上式中第二项与 y_k^t 无关，所以：

$$\frac{\partial p(l|x)}{\partial y_k^t} = \frac{\partial \sum_{\pi \in B^{-1}(l), \pi_t = l_k} p(\pi|x)}{\partial y_k^t}$$

而上述 $\frac{\partial p(l|x)}{\partial y_k^t}$ 就是恰好与概率 y_k^t 相关的路径，即 t 时刻都经过 l_k（$\pi_t = l_k$ ）。

举例说明，还是看上面的例子 π_1, π_2 （这里的下标 $1, 2$ 代表不同的路径）：

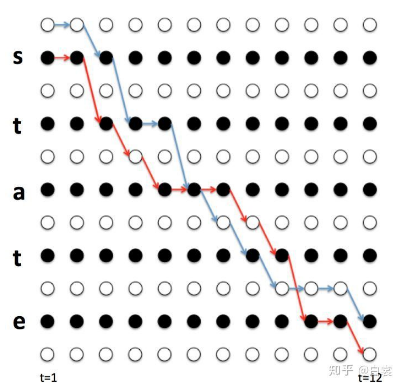

蓝色路径 π_1 ：

$$B(\pi_1)=B(--s\,t\,t\,a-t---e)=state$$

$$p(\pi_1|x)=y^1_-\cdot y^2_-\cdot y^3_s\cdot y^4_t\cdot y^5_t\cdot y^6_a\cdot y^7_-\cdot y^8_t\cdot y^9_-\cdot y^{10}_-\cdot y^{11}_-\cdot y^{12}_e$$

红色路径 π_1 ：

$$B(\pi_2)=B(s\,s\,t-a\,a\,a-t\,e\,e-)=state$$

$$p(\pi_2|x)=y^1_s\cdot y^2_s\cdot y^3_t\cdot y^4_-\cdot y^5_a\cdot y^6_a\cdot y^7_a\cdot y^8_-\cdot y^9_t\cdot y^{10}_e\cdot y^{11}_e\cdot y^{12}_-$$

还有 π_3,π_4 没有画出来。

而 π_1,π_2,π_3,π_4 在 $t=6$ 时恰好都经过 $\pi_6=a$ （此处下标代表路径 π 的 t 时刻的字符）。所有类似于 π_1,π_2,π_3,π_4 经过 B 变换后结果是 $l=state$ 且在 $\pi_6=a$ 的路径集合表示为 $\{\pi|\pi\in B^{-1}(l),\pi_6=a\}$ 。

观察 π_1,π_2,π_3,π_4 。记 π_1 蓝色为 $b(blue)$ ， π_2 红色路径为 $r(red)$ ， π_1,π_2 可以表示:

$$\pi_1=b=b_{1:5}+a_6+b_{7:12}$$

$$\pi_2=r=r_{1:5}+a_6+r_{7:12}$$

那么 π_3,π_4 可以表示为:

$$\pi_3=b_{1:5}+a_6+r_{7:12}$$

$$\pi_4=r_{1:5}+a_6+b_{7:12}$$

计算:

$$\begin{aligned}\frac{\partial p(l|x)}{\partial y^6_a}&=\frac{\partial\sum_{\pi\in B^{-1}(l),\pi_6=a}p(\pi|x)}{\partial y^6_a}\\&=\frac{\partial p(\pi_1|x)+\partial p(\pi_2|x)+\partial p(\pi_3|x)+\partial p(\pi_4|x)+\dots}{\partial y^6_a}\end{aligned}$$

为了观察规律，单独计算 $p(\pi_1|x)+p(\pi_2|x)+p(\pi_3|x)+p(\pi_4|x)$ 。

$$\begin{aligned}&p(\pi_1|x)+p(\pi_2|x)+p(\pi_3|x)+p(\pi_4|x)\\&=y^1_-\cdot y^2_-\cdot y^3_s\cdot y^4_t\cdot y^5_t\cdot y^6_a\cdot y^7_-\cdot y^8_t\cdot y^9_-\cdot y^{10}_-\cdot y^{11}_-\cdot y^{12}_e\\&\quad+y^1_s\cdot y^2_s\cdot y^3_t\cdot y^4_-\cdot y^5_a\cdot y^6_a\cdot y^7_a\cdot y^8_-\cdot y^9_t\cdot y^{10}_e\cdot y^{11}_e\cdot y^{12}_-\\&\quad+y^1_-\cdot y^2_-\cdot y^3_s\cdot y^4_t\cdot y^5_t\cdot y^6_a\cdot y^7_a\cdot y^8_-\cdot y^9_t\cdot y^{10}_e\cdot y^{11}_e\cdot y^{12}_-\\&\quad+y^1_s\cdot y^2_s\cdot y^3_t\cdot y^4_-\cdot y^5_a\cdot y^6_a\cdot y^7_-\cdot y^8_t\cdot y^9_-\cdot y^{10}_-\cdot y^{11}_-\cdot y^{12}_e\end{aligned}$$

不妨令:

$$\text{backward} = p(b_{7:12} + r_{7:12}|x) = y_-^7 \cdot y_t^8 \cdot y_-^9 \cdot y_-^{10} \cdot y_-^{11} \cdot y_e^{12} + y_a^7 \cdot y_-^8 \cdot y_t^9 \cdot y_e^{10} \cdot y_e^{11} \cdot y_-^{12}$$

那么 $p(\pi_1|x) + p(\pi_2|x) + p(\pi_3|x) + p(\pi_4|x)$ 可以表示为：

$$p(\pi_1|x) + p(\pi_2|x) + p(\pi_3|x) + p(\pi_4|x) = \text{forward} \cdot y_a^t \cdot \text{backward}$$

推广一下，所有经过 B 变换为 l 且 $\pi_6 = a$ 的路径（即 $\{\pi|\pi \in B^{-1}(l), \pi_6 = a\}$ ）可以写成如下形式：

$$\sum_{\pi \in B^{-1}(l), \pi_6 = a} p(\pi|x) = \text{forward} \cdot y_a^t \cdot \text{backward}$$

进一步推广，所有经过 B 变换为 l 且 $\pi_t = l_k$ 的路径（即 $\{\pi|\pi \in B^{-1}(l), \pi_t = l_k\}$ ）也都可以写作：

$$\sum_{\pi \in B^{-1}(l), \pi_t = l_k} p(\pi|x) = \text{forward} \cdot y_{l_k}^t \cdot \text{backward}$$

所以，定义forward $\alpha_t(s)$ ：

对于一个长度为 T 的路径 π ，其中 $\pi_{1:t}$ 代表该路径前 t 个字符， $\pi_{t:T}$ 代表后 $T-t$ 个字符。

$$\alpha_t(s) = \sum_{\pi \in B(\pi_{1:t}) = l_{1:s}} \prod_{t'=1}^{t} y_{\pi_{t'}}^{t'}$$

其中 $\pi \in B(\pi_{1:t}) = l_{1:s}$ 表示前 t 个字符 $\pi_{1:t}$ 经过 B 变换为的 $l_{1:s}$ 的前半段子路径。 $\alpha_t(s)$ 代表了 t 时刻经过 l_s 的路径概率中 $1 \sim t$ 概率之和，即前向概率。

由于当 $t=1$ 时路径只能从blank或 l_1 开始，所以 $\alpha_t(s)$ 有如下性质：

$$\alpha_1(-) = y_-^1$$

$$\alpha_1(l_1) = y_{l_1}^1$$

$$\alpha_1(l_t) = 0 \text{ , } \forall t > 1$$

如上面的例子中 $T=12$, $l = state$, $l_{1:3} = sta$ 。对于所有 $\pi \in B(\pi_{1:6}) = l_{1:3}$ 路径，当 $t=1$ 时只能从blank和 s 字符开始。

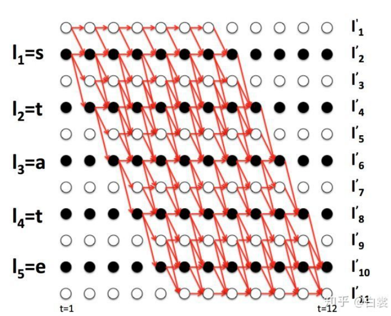

图15

$$\alpha_6(a)=(\alpha_5(a)+\alpha_5(t)+\alpha_5(-))\cdot y_a^6$$

也就是说，如果 $t=6$ 时刻是字符 a ，那么 $t=5$ 时刻只可能是字符 $a,t,blank$ 三选一，否则经过 B 变换后无法压缩成 $l=state$ 。

那么更一般的：

$$\alpha_t(l'_k)=(\alpha_{t-1}(l'_k)+\alpha_{t-1}(l'_{k-1})+\alpha_{t-1}(-))\cdot y_{l'_k}^t$$

同理，定义backword $\beta_t(s)$ ：

$$\beta_t(s)=\sum_{\pi\in B(\pi_{t:T})=l_{s:|l|}}\prod_{t'=t}^{T}y_{\pi_{t'}}^{t'}$$

其中 $\pi\in B(\pi_{t:T})=l_{s:|l|}$ 表示后 $T-t$ 个字符 $\pi_{t:T}$ 经过 B 变换为的 $l_{s:|l|}$ 的后半段子路径。 $\beta_t(s)$ 代表了 t 时刻经过 l_s 的路径概率中 $t\sim T$ 概率之和，即后向概率。

由于当 $t=T$ 时路径只能以blank或 $l_{|l'|-1}$ 结束，所以有如下性质：

$$\beta_T(-)=y_-^T$$
$$\beta_T(l'_{|l'|-1})=y_{l'_{|l'|-1}}^T$$
$$\beta_T(l'_{|l'|-i})=0\ ,\ \forall i>1$$

如上面的例子中 $T=12$ ，$l=state$ ，$|l|=|state|=5$ ，$l_{3:5}=ate$ 。对于所有 $\pi\in B(\pi_{6:12})=l_{3:6}$ 路径，当 $t=12$ 时只能以 $l'_{|l'|}=l'_{11}=-$ （blank字符）和 $l'_{|l'|-1}=l'_{10}=e$ 字符结束。

同理对于 $\beta_t(s)$ 有如下递推关系：

$$\beta_t(l'_k)=(\beta_{t+1}(l'_k)+\beta_{t+1}(l'_{k+1})+\beta_{t+1}(-))\cdot y_{l'_k}^t$$

那么forward和backward相乘有：

$$\alpha_t(l'_k)\beta_t(l'_k))=\sum_{\pi\in B^{-1}(l),\pi_t=l'_k}y_{l'_k}^t\prod_{t=1}^{T}y_{\pi_t}^t$$

或：

$$\alpha_t(l_k)\beta_t(l_k))=\sum_{\pi\in B^{-1}(l),\pi_t=l_k}y_{l_k}^t\prod_{t=1}^{T}y_{\pi_t}^t$$

注意， $y_{l_k}^t$ 与 $y_{l'_k}^t$ 可以通过图15的关系对应，如 $y_{l_1}^t=y_{l'_2}^t$ ， $y_{l_2}^t=y_{l'_4}^t$ 。

对比 $p(l|x)$ ：

可以得到 $p(l|x)$ 与forward和backward递推公式之间的关系：

$$p(l|x) = \sum_{\pi \in B^{-1}(l), \pi_t = l_k} \frac{\alpha_t(l_k)\beta_t(l_k)}{y_{l_k}^t}$$

训练CTC

对于LSTM，有训练集合 $S = \{(x_1, z_1), (x_1, z_1), \ldots, (x_N, z_N)\}$ ，其中 x 是图片经过CNN计算获得的Feature map， z 是图片对应的OCR字符label（label里面没有blank字符）。

现在我们要做的事情就是：通过梯度 $\frac{\partial p(l|x)}{\partial w}$ 调整LSTM的参数 w，使得对于输入样本为 $\pi \in B^{-1}(z)$ 时有 $p(l|x)$ 取得最大。**所以如何计算梯度才是核心。**

单独来看CTC输入（即LSTM输出） y 矩阵中的某一个值 y_k^t （注意 y_k^t 与 $y_{l_k}^t$ 含义相同，都是在 t 时 $\pi_t = l_k$ 的概率）：

$$\begin{aligned}\frac{\partial p(l|x)}{\partial y_k^t} &= \frac{\partial \sum_{\pi \in B^{-1}(l), \pi_t = l_k} \frac{\alpha_t(l_k)\beta_t(l_k)}{y_{l_k}^t}}{\partial y_{l_k}^t} \\ &= -\frac{\sum_{\pi \in B^{-1}(l), \pi_t = l_k} \alpha_t(l_k)\beta_t(l_k)}{(y_{l_k}^t)^2}\end{aligned}$$

注意，上式中的任意的 $\alpha_t(l_k)\beta_t(l_k)$ 都可以通过递推快速计算，即也可以快速通过递推计算获得梯度 $\frac{\partial p(l|x)}{\partial y_k^t}$ 。之后就好办了，梯度下降算法你懂的。 CRNN方法难点就在于CTC的理解。

CTC总结

CTC是一种Loss计算方法，用CTC代替Softmax Loss，训练样本无需对齐。CTC特点：

- 引入blank字符，解决有些位置没有字符的问题
- 通过递推，快速计算梯度

看到这里你也应该大致了解MFCC+CTC在语音识别中的应用了（图16来源）。

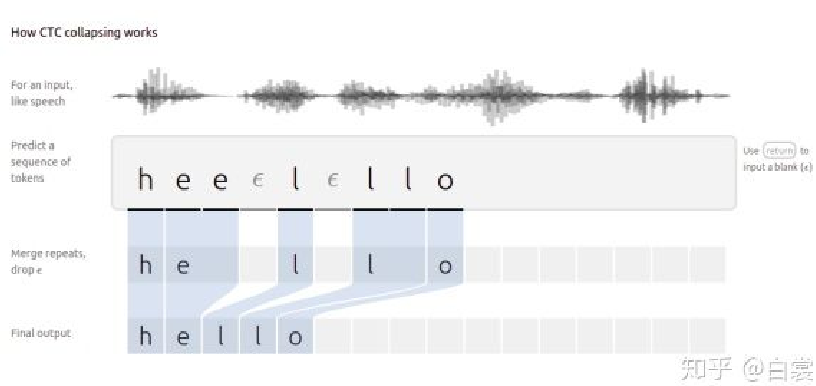

图16 MFCC+CTC在语音识别中的应用

这篇文章的核心，就是将CNN/LSTM/CTC三种方法结合：

- 首先CNN提取图像卷积特征
- 然后LSTM进一步提取图像卷积特征中的序列特征
- 最后引入CTC解决训练时字符无法对齐的问题

即提供了一种end2end文字图片识别算法，也算是OCR方向的简单入门文章。

想了解如何使用CNN+Seq2Seq+Attention进行OCR的小伙伴请点击下面的链接：

完全解析RNN, Seq2Seq, Attention注意力机制
zhuanlan.zhihu.com

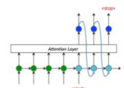

本文仅为OCR（文本行识别）的入门教程。

至于版面分析，汉字识别，准召优化这些问题不在讨论范围，请勿提问。

编辑于昨天 10:22

卷积神经网络（CNN） OCR（光学字符识别） 文字识别（技术）

文章被以下专栏收录

机器学习随笔 进入专栏

推荐阅读

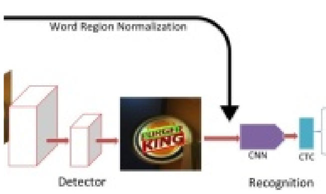

文字识别OCR方法整理

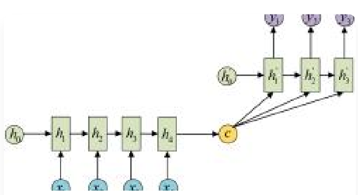

完全图解RNN、RNN变体、Seq2Seq、Attention机制

何之源

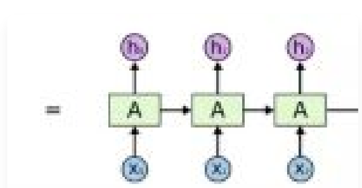

关于序列建模，是时候抛弃RNN和LSTM了

机器之心 发表于机器之心

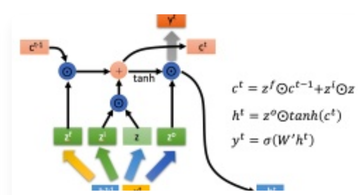

人人都能看懂的LSTM

陈诚